

YOLO と DeepSORT を用いた大学食堂の入退室人流カウントにおける最適化手法の検討

前田 守海, 畔上 昂大, 高波 知弘, 本野 健斗, 有賀 勇斗, 陳 寅, 新井 亜弓*
麗澤大学 工学部*

1 はじめに

近年, 各種のセンシング技術の普及により, 人の移動や滞在に関する人流データが詳細かつ高速に取得可能になった. これらの人流データは交通機関や商業施設における混雑回避などの身近な情報提供サービスや, 行政機関における交通・観光といった地域課題への利用など, 多分野での活用が進みつつある [1].

また, 深層学習技術の発展に伴い, カメラ映像を用いる人流カウントシステムは公共安全, 都市計画など多様な分野で注目を集めている. 特に YOLO をはじめとする物体検出アルゴリズムと, DeepSORT などのトラッキングアルゴリズムを組み合わせたカメラベースのシステムについて, 多くの研究が進められている [2].

しかし, これらの手法を実用化のために, 計算資源やカメラ設置条件など現場特有の制約がある実環境に適用する際には, 追加の最適化が必要な場合がある. さらに, 出入口のようなすれ違いの発生する狭路という状況ではオクルージョン (密集時の重なり) が発生しやすく, 高精度な人流カウントの実用化は困難である. [2].

そこで本稿では, 麗澤大学の学生食堂を対象に, YOLO と DeepSORT を用いた人流カウントシステムを構築し, 特に昼食時の混雑時のように現場特有の制約がある実環境下における精度向上のための最適化手法を検討する. 特に, カウンタラインの線分化, アルゴリズムのパラメータの最適化など, 制限環境下での精度向上に有効な最適化手法を検討する.

2 システム構成

本研究では, YOLO による物体検出と DeepSORT による追跡を組み合わせ, カウンティングラインを

用いた入退室判定を行う人流カウントシステムを Python で構築した.

2.1 モデル選択

使用した YOLO のモデルは YOLO11n である. YOLO11 は以前のバージョンと比べて軽量ながら精度が向上している. さらに mAP(mean Average Precision) が過去のモデルと比較しても最高のスコアを達成している [3]. そのため, 本研究ではその中で最も軽量のバリエーションである YOLO11n を使用する. また, トラッキングアルゴリズムは DeepSORT を使用する.

2.2 カウンタラインの設定方法

従来のカウンタラインは直線を用いており [4], 画角全体をカバーすることが可能な反面, カメラの画角に制限のある環境下では入退室とは関係の無い人流をカウントしてしまう可能性がある. そこで本研究では, より柔軟に設定することができる線分を用いたカウンタラインを採用した. 直線を設定する際には傾きと切片を用いて記述していたが, 線分を採用したため, 線分の始点と終点の座標を用いて記述する. さらに, ピクセル座標ではなく, 画像の解像度に依存しない正規化座標を使用する. これは画像の幅 W , 高さ H に対し, 左上を $(0, 0)$, 右下を $(1, 1)$ とする相対比率で表現したものである. 例として, 1920×1080 の解像度でピクセル座標 $(960, 540)$ は正規化座標 $(0.5, 0.5)$ と表現され, 異なる解像度の動画にも適用可能となる.

3 実験

3.1 実験環境

麗澤大学の学生食堂において, 2025 年 10 月から 12 月にかけて継続的にデータ収集を行った. 食堂の入退室口 2 箇所にカメラを設置し, 長時間の動画データを取得した. 学生食堂は昼食時間帯 (12:00 から 13:00) に混雑のピークを迎えるため, この時間帯を中心にデータを収集した.

* Optimization of YOLO- and DeepSORT-Based People Counting for a University Cafeteria
Moriyumi Maeda, Kohda Azegami, Tomohiro Takanami, Kento Motono, Yuto Ariga, Yin Chen, Ayumi Arai, Faculty of Engineering, Reitaku University

3.2 データ収集

取得した動画データからは、各入退室口における入室人数 (IN)、退室人数 (OUT)、および時刻情報を 1 分単位で記録し、CSV ファイルとして出力した。

4 分析




図 1 1 日の人数動向の平均

図 1 は分析システムから出力されたデータを可視化したものである。12:20 の授業終了時に入場者がピークを迎え、13:10 の授業開始時には退場者が多い傾向が確認され、これにより、本システムが実際の混雑傾向を捉えられていることが確認できた。

5 パラメータ最適化の検証

本研究で開発した人流カウントシステムは、大学食堂における実運用を想定し、待ち時間予測のためのリアルタイム動画処理パイプラインに統合される。当該パイプラインは、処理負荷が利用可能な計算資源を上回る場合に、フレームスキップ等の負荷軽減手法を動的に適用することで、資源制約下においてもリアルタイムに待ち時間予測の提供を実現することを目指して開発されている。フレームスキップとは、一定間隔でフレームを間引いて処理する手法であり、処理速度を向上させる一方で、物体追跡の連続性に影響を与える。そのため、フレームスキップの影響を受けると考えられる DeepSORT のパラメータ n_init について、フレームレートに応じた最適値を検討した。 n_init は、新規に検出された物体が追跡状態に移行するために必要な連続検出フレーム数である。評価データセットとして、2025 年 12 月 8 日および 9 日の 11:30~14:00 にカメラ 1 で撮影された映像を使用した。これらは 1 分単位の計 300 本の動画クリップで構成されている。各クリップにおけるグラウンドトゥルースは、全動画を目視によりカウントすることで作成した。なお、当該パイプラインは通常時に 15FPS、高負荷時に 5FPS で動作するため、検証では条件としてこれらの値を採用した。

表 1 に検証結果を示す。15FPS 環境では n_init による精度差はわずかであったが、5fps 環境では $n_init=1$ の設定が $n_init=3$ と比較して約 4% 高

表 1 n_init パラメータの評価結果

FPS	n_init	カウント平均精度 (SE)
15	1	88.89% ($\pm 1.39\%$)
15	3	89.11% ($\pm 1.36\%$)
5	1	88.03% ($\pm 1.40\%$)
5	3	84.21% ($\pm 1.54\%$)

い精度を示し、15FPS 環境と同等の精度 (88.03%) を維持できることが明らかになった。

この要因として、実時間における追跡確定までの遅延が挙げられる。 $n_init=3$ の場合、追跡確定までに要する時間は 15FPS で 0.2 秒であるのに対し、5FPS では 0.6 秒を要する。食堂の出入口のような狭い画角において、0.6 秒の遅延は人がカウトラインを通過してしまうのに十分な時間であり、結果としてカウント漏れが発生したと考えられる。一方、5FPS 環境下で n_init を 1 に設定することで、追跡確定までの時間を 0.2 秒に短縮することが出来た。以上から、計算資源の制約によりフレームスキップを行う際は、フレームレートの低下比率に合わせて n_init を小さくすることで、計算負荷を軽減しつつ、高 FPS 時と同等の精度を維持できるという知見が得られた。

6 おわりに

本稿では、大学食堂における YOLO と DeepSORT を用いた人流カウントシステムの最適化手法について述べた。特に、計算資源の制約によりフレームレートを低下させる際、追跡パラメータ n_init を最適化することで、計算負荷を削減しつつ精度を維持できることを明らかにした。今後は、カメラの設置角度や画角によって変化するオクルージョンの発生頻度を定量的に評価し、それらが IoU 閾値や信頼度閾値の最適値に与える影響を分析することで、環境適応的なパラメータ決定手法の確立を目指す。

謝辞

本研究は麗澤大学地域創生 (連携)・PBL 奨励金 (課題名: SMART 食堂人流センシング) の助成を受けて実施された。

参考文献

- [1] 国土交通省: 地域課題解決のための人流データ活用の手引き 改訂版 v1.2 (2024).
- [2] H. Bai, J. Mao, and S.-H. G. Chan: "A survey on deep learning-based single image crowd counting: Network design, loss function and supervisory signal," *Neurocomputing*, Vol.508, pp.1 - 18, 2022. DOI: 10.1016/j.neucom.2022.08.037.
- [3] Ultralytics: "YOLO11 vs YOLOv8: Architectural Evolution and Performance Analysis," *Ultralytics YOLO Docs*, <https://docs.ultralytics.com/models/yolo11/> (accessed 2026-01-05).
- [4] W. Huang, Y. Chen, J. Nakazawa, and T. Okoshi: "AdaLine: Adaptive Counting Line Optimization by Perspective-Aware Trajectory Modeling in Object-Detection-Tracking Systems," *IEEE Access*, Vol.13, pp.111282 - 111292, 2025. DOI: 10.1109/ACCESS.2025.3582577.